

FINAL REPORT · 2026

Block Blast — Deep RL

在 8×8 拼圖上比較 DQN、PPO 與 Reward Shaping

課程 深度強化學習

Member A 環境 · Member B DQN · Member C PPO · Member D Reward · Member E Baseline & 整合

三個挑戰，兩個 Research Question

01

稀疏 Reward

消行才有 +1，多步規劃才能看到回饋

02

192 維離散動作

大多動作不合法，需要 action masking

03

不可逆死局

塞滿即結束、無 undo，需要前瞻保守策略

04

RQ1 PPO vs DQN

在相同 encoder 下，哪個演算法表現較強？

05

RQ2 Sparse vs Dense

Dense reward shaping 能否提升存活與分數？

06

本日章節

Env (A) → DQN (B) → PPO (C) →
Reward (D) → Results (E)

環境

Block Blast Gym

8×8 盤面，每回合給 3 個隨機方塊；
Gymnasium 標準介面，所有 agent 共用。

Observation

Dict(board=(8,8) float32 , pieces=(3,5,5) float32)。每個 piece 被渲染成自己的 5×5 binary grid；用掉的 slot 全 0。

Action

Discrete(192) = piece_idx × 64 + row × 8 + col。env.encode_action / _decode_action 是唯一座標系。

Reward

Sparse：消行 +1、死亡 -10 | Dense：
sparse + $(-0.02 \times \text{holes} - 0.01 \times \text{bumpiness})$

Board

(8,8) float32 盤面

Pieces

(3,5,5) 三個方塊

Action

Discrete(192) 扁平整數

四個必須記住的不變式

- 1 三個方塊全用完，env 才補新方塊
- 2 info["action_mask"] 在 reset() 與 step() 都會更新
- 3 terminated = not np.any(mask) — 死亡就是「沒合法動作」
- 4 obs_to_tensor 已處理 batched / single + CNN channel，agent 不要重造

Action Masking — 192 個動作裡平均只有個位數合法

Masking

為什麼是強制

未遮罩 → 大量非法動作會被選中，agent 學垃圾；env 本身會接受非法動作，甚至 crash。三條 baseline / DQN / PPO 都受影響。

DEATH = NO LEGAL

terminated 條件

`terminated = not np.any(env.action_masks())`。「死亡偵測」與「合法動作偵測」是同一件事，這也是為什麼 mask 必須先算。

四個 agent 各自怎麼用 mask

效果相同：把非法動作機率歸零（or Q 值設 $-\infty$ ）

MaskablePPO

`auto-pull info["action_mask"]`

推薦

自製 PPO

`logits[~mask] = -inf` 再 Categorical

本專案 C

自製 DQN

`Q[~mask] = -inf` 後 `argmax`

本專案 B

Random Baseline

`uniform-from-legal` (mask 後均勻抽)

Baseline

共用 CNN Backbone — 為了公平比較演算法

PURPOSE

DQN 與 PPO 使用同一個 encoder。任何性能差距都來自演算法本身，不來自 representation。

01

Board Branch

盤面分支

board (8,8) $\rightarrow$ Conv $3 \times 3 \rightarrow$ Conv $3 \times 3 \rightarrow$ flatten $\rightarrow$ FC(128)。CNN 捕捉局部填滿樣態。

02

Pieces Branch

方塊分支

pieces (3,5,5) $\rightarrow$ flatten $\rightarrow$ FC(64)
。當前三個可用方塊的緊湊向量表示。

03

Heads

演算法頭部

Concat (128+64) $\rightarrow$ FC(128) $\rightarrow$ 兩個出口：DQN 得 (B, 192) Q values；PPO 得 (B, 192) logits + (B, 1) value。

POLICY

鎖死 encoder 是有意的設計決定。修改 agents/network.py 會讓 B 與 C 的對比失效——所以這個檔案有 hard rule 禁止單方修改。

Double DQN — 為了壓 overestimation

ALGORITHM · Double DQN

Member B

為什麼用 Double DQN

Vanilla DQN 的 $\max$ 操作會系統性高估 Q 值；Double DQN 用 online net 選動作、target net 估值，兩個網路解耦。

Replay 與探索

Replay buffer 500k · batch 32 隨機抽。ε-greedy 從 1.0 線性 decay 到 0.05，跨 400k steps。

✓ *Sparse* 與 *Dense* 兩組 reward 各跑 1M steps，皆有收斂；曲線見下一頁

Hyperparameter 一覽

online_net

線上網路

選擇動作 $\arg\max Q(s, \cdot)$ ；參數每 step 更新**target_net**

目標網路

soft update $\tau=0.005$ ，產生穩定的 TD target**replay_buffer**

經驗回放

500k transitions、batch 32 隨機抽，打破時間相關性

epsilon

ε-greedy 探索

1.0 → 0.05 over 400k steps，避開早期過度貪婪

loss

Huber Loss

對 outlier 比 MSE 穩定；mask 後對 $Q[\sim\text{mask}]$ 不算 loss

DQN 結果 — 有學到，但未超越 Greedy baseline

RESULTS · DQN

在相同的 CNN backbone 與 action masking 下，1M 訓練步後的 100 局 eval 平均分數

100 局 evaluation 結果

- 01** DQN sparse 平均分數
1.46 (比 Random 1.35 略高，但差距有限)
- 02** DQN dense 平均分數
2.43 (+66% over sparse ; dense shaping 對 DQN 有顯著效果)
- 03** 對照 Greedy baseline
Greedy 一步前瞻 = 4.32，DQN 仍明顯落後 baseline
- 04** 對照 Random baseline
Random uniform-from-legal = 1.35，DQN sparse 領先有限

為什麼會卡在這裡

DIAGNOSIS

Q-learning 在 192 維離散動作 + 稀疏 reward 下 sample efficiency 不足； ϵ -greedy 探索難以發現 multi-step 連消的 reward 序列

訓練曲線

sparse / dense 兩條都收斂

1M steps 內 dense 持續壓過 sparse

下一步

更長訓練 / 改用 PPO

PPO (下一段) 的策略梯度更適合長步規劃，dense 下達 4.15 已接近 Greedy

PPO 設定 — 自製 PPO + Action Masking

ALGORITHM · Custom PPO

不使用 SB3-contrib MaskablePPO，但行為對齊：rollout、advantage、masked categorical 全部自刻，與 DQN 用同一個 BlockBlastActorCritic 網路。

1

clip_range**PPO 截斷係數**

0.2 （標準設定；過大會破壞 trust region）

ratio = $\pi_{\text{new}} / \pi_{\text{old}}$ ，clip 在 $[1-\epsilon, 1+\epsilon]$ 內避免單步更新過大

2

GAE λ **advantage 平滑度** $\lambda = 0.95$ ， $\gamma = 0.99$ GAE 把 TD 殘差以 λ 衰減累加，bias-variance trade-off 的標準設定

3

learning_rate**Adam 學習率**

3e-4 （太大會 KL 爆炸，見下頁踩坑）

搭配 entropy coef 0.01 維持探索；訓練後期視 approx_kl 微調

4

rollout_steps**每次更新的樣本數**

2048 steps × 4 epoch、minibatch 64

rollout 收集後做 4 epoch update；advantage 標準化加速收斂

NOTE action masking 邏輯與 MaskablePPO 一致—— $\text{logits}[\sim\text{mask}] = -\text{inf}$ 後再走 Categorical，policy gradient 自動忽略非法動作；保證 ratio 計算無偏。優勢函數採 GAE，advantage 標準化加速收斂。值函數頭與策略頭共享 backbone，更新時 value loss 與 policy loss 加權合併。

踩過的坑 — Dense reward 係數要降一個數量級

V1 · PROPOSAL 預設

$-0.1 \times \text{holes} - 0.05 \times \text{bumpiness}$

value_loss 爆到 ~150

每步 shaping 約 $-1 \sim -3$ ，遠蓋過 $+1$ line clear。
approx_kl > 0.05，policy 被 clip 出去；agent 學會「早死避免累積負分」。

V2 · 實際採用

$-0.02 \times \text{holes} - 0.01 \times \text{bumpiness}$

value_loss < 1，正常收斂

係數降為原本的 $1/5 \sim 1/10$ 。shaping 成為輕推力而非主導；critic 學得穩定，policy 朝消行方向收斂，平均分數推到 4.15。

TAKEAWAY

Reward shaping 不只方向 (+/-) 重要，magnitude 也決定能不能學。診斷鏈完整紀錄在 docs/ppo_journey.md，是這個 project 最關鍵的工程教訓。

PPO 學習曲線 — Dense 達 4.15，接近 Greedy 4.32

SPARSE

Sparse Reward

mean 2.82

1M steps × 100 局 eval

✓ reward = +1 (line)

✓ reward = -10 (death)

✓ 其他狀態
reward = 0

✓ 完全依賴 episode return

✓ 探索靠 entropy
bonus✓ policy 須學「整段消行」
才會看到 +1✓ 700k 步
後 plateau✓ 終局接近
2.82✓ 顯著勝過
Random 1.35

✓ 仍落後 Greedy 4.32

PLATEAU

Sparse 訓練的瓶頸

缺乏中間訊號 → 多步規劃靠運氣；exploration 與 exploitation 平衡靠 entropy 衰減

DENSE

Dense Reward

mean 4.15 ★

額外訊號

每步加 $(-0.02 \times \text{holes} - 0.01 \times \text{bumpiness})$ ；agent 學會維持「低、平、無洞」的盤面，作為消行的前置條件。

TREND

未 plateau，仍在上升

1M 步時曲線斜率為正；再訓 500k 估計超越 Greedy 4.32。Ablation 贏家。

Sparse vs Dense — 兩種 reward 設計

1

SPARSE 原始稀疏訊號

Member D 的對照組

- +1 每消一行或一列
- -10 塞滿、無合法動作時 terminated
- 0 其他所有 step
- agent 只能靠 episode return 學

強學習訊號，但極稀疏——對 *sample efficiency* 要求很高

2

DENSE 盤面健康度微訊號

Member D 的實驗組

- Sparse 全部保留
- + $(-0.02 \times \text{holes})$ 每個被遮住的空格扣分
- + $(-0.01 \times \text{bumpiness})$ 相鄰列高度差扣分
- agent 學會「低、平、無洞」

把長期目標分解為每步可感知的訊號——*line-clear* 變成「結果」而非「唯一回饋」

3

MAGNITUDE 為何係數要這麼小

本專案最關鍵的工程教訓

- Proposal 預設 -0.1 / -0.05
- → 每步 shaping $\sim -1 \sim -3$
- → 蓋過 +1 line-clear
- → value_loss ~ 150 、KL > 0.05
- → agent 學會「早死避免累積」

降為 -0.02 / -0.01 (1/5~1/10) 後
value_loss < 1 ，正常收斂。詳見
[docs/ppo_journey.md](#)。

結果一覽 — 四個 agent × 兩種 reward

— Random · sparse

mean_score 1.35 · mean_steps 12.75

- Baseline。每步從合法動作中均勻抽取。1.35 分代表「閉著眼亂玩」可達分數的底線。

— Greedy · sparse

mean_score 4.32 · mean_steps 18.27

- 強 baseline。每步窮舉 192 動作，挑下一步 line-clear 數最大者。沒有 learning，純粹一步前瞻。

— DQN · sparse

mean_score 1.46 · mean_steps 12.82

- 1M 步訓練後僅略勝 Random。Q-learning 在大離散動作空間 + 稀疏 reward 下 sample efficiency 不足。

— DQN · dense

mean_score 2.43 · mean_steps 15.21

- Dense shaping 把 DQN 從 1.46 推到 2.43 (+66%)。仍低於 Greedy，但顯示 shaping 對 DQN 有效。

— PPO · sparse

mean_score 2.82 · mean_steps (待補)

- CLAUDE.md snapshot 數字；100 局正式 eval 由 C 補跑後可更新。Plateau 約在 700k 步出現。

— PPO · dense ★

mean_score 4.15 · mean_steps 18.94

- Ablation 贏家。在 1M 步時仍在上升，已接近 Greedy 4.32。本專案最佳組合。

回答 RQ、Limitations、Future Work

01 RQ1

PPO vs DQN

PPO 顯著勝出。Dense 下 4.15 vs DQN dense 2.43 (+71%)。PPO 的策略連續更新較適合長步規劃；DQN 在 192 維離散動作 + 稀疏 reward 下 sample efficiency 不足。

02 RQ2

Sparse vs Dense

Dense reward 有效。DQN 1.46 → 2.43 (+66%)，PPO 假設 2.82 → 4.15。前提是 reward 係數要夠小——否則 value_loss 爆炸 (PPO 踩坑頁)。

03 Future

下一步可以做的三件事

(reserved)

LIMITATIONS & FUTURE WORK

- 1 Limitations | 單一 seed；500k–1M steps 對 PPO dense 可能不夠（曲線仍在上升）；無公開 benchmark 可比；reward 係數仍待全面 sweep。
- 2 Future Work | (1) BC warm-start：用 Greedy demo 預訓 policy；(2) Transformer / 更大 encoder 提升 representation；(3) Curriculum $4 \times 4 \rightarrow 8 \times 8$ 。詳見 docs/improvement_options.md。

THANK YOU

Questions & Discussion
